面试题目总结

Java 篇

Java 的拷贝

Java 中有浅拷贝和深拷贝之说，对于浅拷贝，当对象中的数据类型是基本类型时，浅拷贝直接进行值拷贝，也就是将该属性的值复制一份给新的对象，对其中一个对象的某个值进行修改不影响另一个对象的值，当对象中的数据类型包含引用类型时（比如成员变量为数组，类的对象），那么浅拷贝会进行引用拷贝，也就是将该成员的引用值（内存地址）复制一份给新的对象，实际上两个对象的该成员指向同一个实例，在一个对象中修改该成员变量会影响另一个对象的该成员的值。

LinkdList 和 ArrayList 的区别

LinkdList 与 ArrayList 都是 List 的实现类，但二者的底层存储不同，ArrayList 使用数组作为存储，查找速度快。LinkdList 使用链表作为存储，删除，插入时只需要移动指针，不像 ArrayList 需要移动元素，比 ArrayList 的速度快，二者都是线程不安全，可以动态扩容（ArrayList 扩容为当前容量的 1.5 倍）。当对查找速度有要求时，建议采用 ArrayList，对插入，删除有要求时，采用后者。

ArrayList 与 Vector 的区别

Vector 的方法是同步的(Synchronized),是线程安全的(thread-safe)，而 ArrayList 的方法不是，由于线程的同步必然要影响性能，因此,ArrayList 的性能比 Vector 好。 当 Vector 或 ArrayList 中的元素超过它的初始大小时,Vector 会将它的容量翻倍,而 ArrayList 只增加 50%的大小，这样,ArrayList 就有利于节约内存空间。当容量不够时进行扩容，使用 Arrays.copyOf(),把原数组复制到新的数组中，这个操作代价很高，因此在创建 ArrayList 对象时就指定大概的容量大小，减少扩容操作的次数

hashMap，为什么会使用红黑树而不是平衡二叉树

红黑树牺牲了一些查找性能 但其本身并不是完全平衡的二叉树。因此插入删除操作效率略高于 AVL 树。AVL 树用于自平衡的计算牺牲了插入删除性能，但是因为最多只有一层的高度差，查询效率会高一些。

http 传输的时候是明文的，怎么解决安全问题

采用 https，访问采用加密方式传输，中间者无法直接查看原始内容

STRING 与 STRINGBUFFER 的区别

String 类一旦产生一个字符串，其对象就不可变。String 类的内容和长度是固定的。如果程序需要获得字符串的信息需要调用系统提供的各种字符串操作方法实现。虽然通过各种系统方法可以对字符串施加操作，但这并不改变对象实例本身，而是生成一个新的实例。Buffer 是缓冲的意思，这个类有缓冲的功能。该类处理可变的字符串。如果要修改一个 StringBuffer 类的字符串，不需要再创建新的字符串对象，而是直接操作原来的串。

String s = new String("xyz");创建了几个 String Object?并作说明

产生两个对象，首先是 new 时产生一个，然后赋给 s 时产生一个

short s1 = 1; s1 = s1 + 1;有什么错? short s1 = 1; s1 += 1;有什么错?

第一个会报错，在 s1+1 时转换成 int 型，而 s1 是 short 类型，直接赋值会导致类型不匹配，可以通过类型转换解决 s1 = （short）(s1+1)。后一个不报错。因为使用了隐式转换

垃圾回收机制

Java 的垃圾回收机制有引用计数法，标记清除算法，标记整理算法，复制回收算法，分代回收算法。

引用计数算法：在堆中为每个对象创建一个引用计数器，当对象被引用时计数器加一，当引用被置为空或者离开作用域，引用计数器减一，当引用计数器为零时，该对象被回收，该方法执行效率高，但不能解决互相引用问题

标记清除算法：分为标记和清除阶段，标记阶段：从应用程序的根对象开始遍历，每一个可以从根对象访问到的对象被标记，否者不标记。清除阶段：从根对象开始，清除那些没有被标记的对象，该算法会产生大量的不连续内存碎片。

标记整理算法：标记过程仍然与“标记-清除”算法一样，但后续步骤不是直接对可回收对象进行清理，而是让所有存活的对象都向一端移动，然后直接清理掉端边界以外的内存。

复制回收算法：在内存中将堆分成两个大小相等块，任何时候只有一个堆被使用。当该堆快被使用完时，此时垃圾回收器会停止程序的运行，将所有还活动的对象复制到另一个堆中，前面那个堆被清空。

分代回收算法：根据堆中对象的年龄，划分老年代与新生代。新生代的存活率低，回收速度

快，采用复制回收算法，只需要付出少量存活对象的复制成本就可以完成收集。而老年代中因为对象存活率高、没有额外空间对它进行分配担保，就必须使用“标记-清理”或“标记-整理”算法来进行回收

Minor GC 与 Full GC 的出发条件及区别

Minor GC 在 Eden 区满时触发，
Full GC 在：
调用 System.gc，系统建议执行 Full GC，但不必然执行
老年代空间不足
方法区空间不足

造成内存泄漏的几种情况

静态集合类引起的内存泄漏：像 HashMap，Vector 等的使用最容易出现内存泄漏，这些静态变量的生命周期和应用程序一致，他们所引用的对象 object 也不能被释放，因为他们被 vector 等集合引用着。
各种连接：比如数据库连接，网络连接，除非显示调用了 close 方法，否者不会被 gc 回收掉。

运行时的数据区域

1. **程序计数器：**记录正在执行的字节码指令地址
2. **Java 虚拟机栈：**每个 java 方法在执行的同时会创建一个栈帧用于存储局部变量表，操作数栈，常量池引用等信息，从方法调用到完成的过程对应一个栈帧在 java 虚拟机栈中入栈和出栈的过程
3. **本地方法栈：**与 java 虚拟机栈类似，只是本地方法栈为本地方法服务
4. **堆：**所有的对象在这里分配内存，是垃圾收集的主要区域，可以通过-Xms 和 -Xmx 指定堆的大小
5. **方法区：**用于存放已被加载的类信息，常量，静态变量，即时编译器编译后的代码等数据

反射

在运行状态中，对于任意一个类，都能够知道这个类的属性和方法，对于任意一个类都能够调用它的属性和方法。这种动态的获取信息和动态调用对象的方法的功能叫做反射
优点：
1. 可扩展性：可以使用全限定名创建可扩展对象的实例，来使用来自外部的用户自定义类
2.
缺点：
1. 性能开销：反射涉及了动态类型解析，所以 jvm 无法对这些代码进行优化。因此反射的操作效率比那些非反射的操作效率低

2. 安全限制：使用反射技术必须要在一个没有安全限值的环境中运行
3. 内部暴露：反射破坏了对象的封装性

Volatile

不保证原子性
保证此变量对所有线程可见
禁止指令重排序优化

ReentrantLock

是一个可重入的互斥锁，又被称为独占锁。ReentrantLock 在同一时间点只能被一个线程访问。但可以被单个线程多次获取。ReentrantLock 包含公平锁和非公平锁，体现在获取锁的机制上。锁是为了保护竞争资源，防止多个线程访问而出错。ReentrantLock 通过一个 FIFO 队列来管理获取该锁的所有线程。在公平锁机制下，线程依次排队获取锁，而非公平锁机制下，不管线程是否在队列的开头，都会竞争锁。**在 finally 中需要释放锁。**

ReentrantLock 与 sychronized 的区别

除了 synchronized 的功能，多了三个高级功能
1. 等待可中断，在持有锁的线程长时间不释放锁的时候，等待的线程可以放弃等待。tryLock(long timeout, TimeUnit unit)
2. 公平锁，按照申请锁顺序来依次获取锁称为公平锁，sychronized 是非公平锁。ReentrantLock 可以通过构造函数实现公平锁。new RenentrantLock(boolean fair)
3. 绑定多个 Condition：通过多次 newCondition 可以获得多个 Condition 对象，可以简单的实现比较负责的线程同步的功能，通过 await(),signal();

除非需要使用 ReentrantLock 的高级功能，否则优先使用 synchronized。这是因为 synchronized 是 JVM 实现的一种锁机制，JVM 原生地支持它，而 ReentrantLock 不是所有的 JDK 版本都支持。并且使用 synchronized 不用担心没有释放锁而导致死锁问题，因为 JVM 会确保锁的释放。

Sleep 与 wait 的区别

1. Sleep 是 Thread 方法，wait 是 Object 方法。
2. 调用 sleep 时，只会让当前线程暂停运行，不会释放获得的锁，而 wait 方法会释放获得的锁。
3. Wait 方法需要在获得锁之后才能调用(通常在 synchronized 方法中调用)，否则会出现异常 IllegalMonitorStateException

线程池

Java 中有五种线程池,分别为 CacheThreadPool,FixedThreadPool,SingleThreadExecutor，ScheduleThreadPool，ScheduledThreadPoolExecutor。他们分别通过 Executors 的静态方法创建出来的，底层是通过 ThreadPollExecutor 实现。

1. CacheThreadPool：工作线程的创建数量几乎没有限制，可以灵活的往线程池中添加线程如果长时间没有往线程池中添加任务,即如果工作线程空闲了指定的时间(默认 1 分钟）则该工作线程终止，终止后如果又提交了新的任务，则线程池重新创建一个工作线程。在使用 CacheThreadPool 时,一定要注意控制任务的数量,否者由于大量线程同时运行，很有可能造成系统瘫痪
2. FixedThreadPool：创建一个指定线程数量的线程池,每提交一个任务就创建一个工作线程，如果工作线程的数目达到线程初始的最大数，则新提交的任务存放到等待队列中。FixedThreadPool 是一个优秀的线程池，它具有线程池提高效率和节省创建线程时所耗的开销。但是在线程池空闲时，也不会释放工作线程，还会占用一定的系统资源
3. SingleThreadExecutor：创建单线程的 Executor，即只创建唯一的工作者线程来执行任务，它只会用唯一的工作线程来执行任务，保证所有的任务按照指定的顺序执行。如果这个线程异常结束，则会有下一个取代他，保证顺序执行。
4. ScheduleThreadPool：创建一个定长的线程池，而且支持定时的以及周期性的任务执行

Shutdown 与 shutdownNow 的区别

Shutdown 设置状态为 Shutdown，而 shutdownNow 设置状态为 stop
Shutdown 只中断空闲线程，已提交的线程继续运行。而 shutdownNow 中断所有的线程
Shutdown 无返回值，shutdownNow 返回值中还有未执行的任务

什么是 CAS

比较并交换，它的作用是将指定内存地址的内容与所给的某个值作比较，如果相等，则将其内容替换为指令中提供的新值，如果不等，则更新失败。从内存领域中来看就是乐观锁，因为它在对共享变量更新之前会比较当前值是否与更新前的值是否相等，如果相等，则更新否则无限循环，直到当前值与更新前的值相等，才执行更新。

数据库篇

索引的实现方式

B+树索引：用于范围查询和单值查询都可以，特别是范围查询
散列索引：Hash 索引适用于单值查询，同时该索引存在一些弊端，无法对范围查询优化，无法利用前缀索引，无法堆排序进行优化，必须回行即通过索引拿到表的位置，必须回到表中取数据。

位图索引：适用于值得类型很少情况，比如男女

InnoDB 与 Myisam 引擎的区别

二者都是用 BTree 索引，但是 Myisam 使用非聚集索引，索引表与数据表相分离，其索引指向某行在磁盘上的位置，不同索引树之间并无关联。InnoDB 使用聚集索引，数据和索引一块存放，其索引指向对主键的引用，非主键索引树指向主键索引

数据库优化

1. Scheme 设计与数据类型优化：选择数据类型只要遵循小而简单的原则就好，越小的数据类型通常会更快，占用更少的磁盘，内存，处理时需要的 cpu 周期也更少。
2. **Mysql 不会使用索引的情况：非独立列**，指的是索引列不能是表达式的一部分，也不能是函数的参数，比如 select * from A where id+1=5,很容易看出其等价于 id=4，但是 mysql 无法自动解析这个表达式，使用函数也是同样的道理
3. 前缀索引：如果列很长，通常可以使用索引列开始的部分字符，这样可以节约索引空间提高索引效率，**只适用于最左前缀查找**
4. 在多数情况下，在多个列上建立独立索引并不能提高查询性能，mysql 不知道使用哪个索引的查询效率更好。这种情况可以通过建立联合索引
5. 使用是索引扫描来排序，只有当索引列的顺序和 order by 的字句的顺序完全一致，并且所有列的排序方向也一样时，才能够使用索引来对结果排序
6.

Spark 篇

RDD 特性

Spark 采用 RDD 以后能够实现高效计算的主要原因如下

1. 高效的容错性：在 RDD 的设计中，数据只读，不可修改，如果要修改数据，必须从父 RDD 转换到子 RDD，由此在不同的 RDD 之间建立了血缘关系。
2. 不同 RDD 之间的转换操作形成依赖关系，可以实现管道化，避免了中间结果的存储，大大降低了数据复制，磁盘 IO 和序列化开销。
3. 每个 RDD 可以分成多个分区，不同分区可以被保存到不同的节点上，从而可以在不同节点上进行并行计算

Watermark

Watermark 用于处理乱序事件的,通常结合窗口来实现。流处理从事件产生,到流经 source，再到 operator，中间是有一个过程和时间的。虽然大部分情况下，流到 operator 的数据都

是按照事件产生的时间顺序来的，但是也不排除由于网络、背压等原因，导致乱序的产生。但是对于 late element，我们又不能无限期的等下去，必须要有个机制来保证一个特定的时间后，必须触发 window 去进行计算了。这个特别的机制，就是 watermark。

Spark 任务调度过程

1. 客户端向资源调度平台的 master 提交任务
2. Master 根据收到的请求与 nodemanager 通信，开启一个 executor 运行 applicationmaster，然后 AM 向 master 注册
3. AM 内部启动 dagscheduleiml 将 DAG 图划分为 stage，生成 taskset，交给 taskschedule 进行调度处理
4. AM 向 master 申请任务运行需要的资源，然后与 nodemanager 通信，开启 container
5. NM 向 AM 请求任务
6. AM 通过 taskscheduleiml 向 NM 分发任务

Hadoop 的调度器有哪些

有三种调度器，分别为默认调度器 FIFO，计算能力调度器 Capacity Scheduler，公平调度器 Fair Scheduler

1. FIFO：先进先出
2. 计算能力调度器 Capability Scheduler：选择占用资源小，优先级高的任务调度
3. 公平调度器 Fair Scheduler：同一队列中的作业公平共享队列中的所有资源

Spark Sql 调优点

对一些 SparkSQL 任务，可以通过缓存数据、调优参数、增加并行度提升性能。
设置缓存： Spark SQL 可以通过调用 spark.catalog.cacheTable("tableName")或者 dataFrame.cache()方法来缓存表。然后，Spark 将会仅仅浏览需要的列并且自动地压缩数据以减少内存的使用以及垃圾回收的压力。可以通过调用 spark.catalog.uncacheTable("tableName")方法在内存中删除表。缓存时可以指定是否压缩 setConf("spark.sql.inMemoryColumnarStorage.compressed","true") ，为每列自动选择压缩码，setConf("spark.sql.inMemoryColumnarStorage.batchSize","1000") ，列式缓存的批处理大小，大批量可以提升内存使用率和压缩了，但是缓存是会有溢出风险
参数调优：
增加并行度： Spark 采用内存列式存储，实际执行查询效率很高，相对而言数据加载阶段耗时较长，合理设置并行度提升文件加载效率

Spark 数据倾斜解决办法

1. 如果 partition 的数据是从外部获取，应当保证数据是可以 split 的，并且保证 split 后的块是均衡的。

2. 如果是 shuffle partition，可以通过调整 shuffle partition 的数目来避免某个 shuffle partition 的数据量过大导致的数据倾斜
3. 如果某个 key 的数据量非常大，调整 partition 的数据也不能解决数据倾斜问题，可以通过对 key 加一些前缀来分散数据
4. 从 shuffle 的角度出发，如果两个 join 表中一个是小表，可以将小表广播出去，变成 BroadcastHashJoin 来消除 shuffle，从而消除 shuffle 引起的数据倾斜。

MapReduce 数据倾斜问题及解决办法

在 mr 模型中数据倾斜通常是因为 key 的分化严重不均，导致一部分数据很多，而另一部分数据很少的情况。

1. 调大 reduce 的内存（增加 reduce 数目适用于唯一值较多的情况）
2. 在 map 端进行聚合
3. 自定义分区，继承 partition 类
4. 重新设计 key，在 key 的前面加一个随机数，待到 reduce 时再把随机数去掉

Spark shuffle

Spark 在 DAG 调度阶段会将一个 Job 划分为多个 Stage，上游 Stage 做 map 工作，下游 Stage 做 reduce 工作，其本质上还是 MapReduce 计算框架。Shuffle 是连接 map 和 reduce 之间的桥梁，它将 map 的输出对应到 reduce 输入中，这期间涉及到序列化反序列化、跨节点网络 IO 以及磁盘读写 IO 等，所以说 Shuffle 是整个应用程序运行过程中非常昂贵的一个阶段

Spark 调优

1. 数据序列化
2. 内存调优：主要包含使用多少内存，接收所有对象的开销，垃圾回收的开销。**Java 对象**处理速度快，但是比原始数据大 2 到 5 倍，因为对象中有 16 字节的对象头。**Java 字符串**在原始字符串数据上有大约 40 个字节的开销（因为它们将它存储在 Chars 数组中并保留额外的数据，如长度），并且由于 String 内部使用 UTF-16 编码而将每个字符存储为两个字节。 因此，10 个字符的字符串可以轻松消耗 60 个字节。主要调节执行内存与存储内存
3. 使用简单的数据结构，避免集合类等，使用基本类型和数组
4. 调大并行度，可以将并行级别作为第二个参数传递（请参阅 spark.PairRDDFunctions 文档），或者设置 config 属性 spark.default.parallelism 以更改默认值。 通常，我们建议群集中每个 CPU 核心有 2-3 个任务。
5. 广播大变量，可以大大减少每个序列化任务的大小，以及在群集上启动作业的成本
6. 数据本地性
7. 持久化 RDD
8. 使用高效的算子。比如使用 reduceByKey，aggregateByKey 取代 groupbyKey，使用 mapPartitions 替代普通 map。使用 foreachPartitions 替代 foreach。使用 filter 之后进行 coalesce 操作：通常对一个 RDD 执行 filter 算子过滤掉 RDD 中以后比较

多的数据后，建议使用 coalesce 算子，手动减少 RDD 的 partitioning 数量，将 RDD 中的数据压缩到更少的 partition 中去，只要使用更少的 task 即可处理完所有的 partition，在某些场景下对性能有提升

9. Shuffle 调优

Spark shuffle 调优

1. **spark.shuffle.file.buffer:**设置 shuffle writer 缓冲区的 buffer 大小，在资源充足的情况下可以设置大一些（默认 32K），减少 shuffle writer 过程中溢写磁盘的次数，提升性能
2. **spark.reducer.maxSizeInFlight:**设置 shuffle read task 的 buffer 缓冲区大小，决定每次能够拉取的数据大小
3. **spark.shuffle.io.maxRetries：**shuffle reader 拉取数据失败时最大重试次数。对于那些特别耗时的 shuffle 操作的作业，建议增大重试次数，以避免由于 jvm 的 full gc 或者网络导致的数据拉取失败，可以提升稳定性
4. **spark.shuffle.memoryFraction:** 代表 executor 内存中分配给 shuffle reader task 执行聚合操作的内存比例。如果内存充足而且很少使用持久化操作，建议调高和这个比例，给 给 shuffle read 的聚合操作更多内存，以避免由于内存不足导致聚合过程中频繁读写磁盘

spark 资源参数设置

1. **num-executors:** 用于设置 Spark 作业总共要用多少个 Executor 进程来执行。每个 spark 作业建议设置 50~100 个较为合适
2. **executor-memory：**设置每个 executor 的内存，建议设置 4-8G。num-executors 乘以 executor-memory，就代表 Spark 作业申请到的总内存量，不要逃超过总内存的 1/3-1/2
3. **executor-cores:**决定了每个 executor 并行执行 task 线程的能力。建议设置 2-4 比较合适 num-executors * executor-cores 不要超过队列总 CPU core 的 1/3~1/2 左右比较合适
4. **driver-memory：**一般默认 1G 就足够了，如果需要使用 collect 等算子将数据全部拉取到 driver 上处理，则需要确保 driver 有足够的内存，以免 oom
5. **spark.default.parallelism:**用于设置每个 stage 默认的 task 数。这个参数极为重要。Spark 官网建议的设置原则是，设置该参数为 num-executors * executor-cores 的 2~3 倍较为合适
6. **spark.storage.memoryFraction:**设置 RDD 持久化数据在 executor 内存中占有的比例。当 shuffle 操作较多时应当调小，如果有较多的持久化应当调大
7. **spark.shuffle.memoryFraction:**

```
spark-submit \
--master yarn-cluster \
--num-executors 100 \
--executor-memory 6G \
--executor-cores 4 \
--driver-memory 1G \
```

```
--conf spark.default.parallelism=1000 \
--conf spark.storage.memoryFraction=0.5 \
--conf spark.shuffle.memoryFraction=0.3 \
```

Spark 比 hadoop 快的原因

1. spark 使用先进的 DAG 执行引擎，支持循环数据流与内存计算，基于内存的执行速度比 hadoop 快上百倍，基于磁盘的执行速度也能快上 10 倍
2. 提供众多的算子，操作更方便
3. Spark 提供了基于内存的计算，中间结果直接放到内存中，带来了更高的迭代运算效率

Spark 为什么快，Spark SQL 一定比 Hive 快吗

Spark SQL 比 Hadoop Hive 快，是有一定条件的，而且不是 Spark SQL 的引擎比 Hive 的引擎快，相反，Hive 的 HQL 引擎还比 Spark SQL 的引擎更快。其实，关键还是在于 Spark 本身快。

消除了冗余的 HDFS 读写：Hadoop 每次 shuffle 操作后，必须写到磁盘，而 Spark 在 shuffle 后不一定落盘，可以 cache 到内存中，以便迭代时使用。如果操作复杂，很多的 shufle 操作，那么 Hadoop 的读写 IO 时间会大大增加，也是 Hive 更慢的主要原因了

消除了冗余的 MapReduce 阶段：Hadoop 的 shuffle 操作一定连着完整的 MapReduce 操作，冗余繁琐。而 Spark 基于 RDD 提供了丰富的算子操作，且 reduce 操作产生 shuffle 数据，可以缓存在内存中。

JVM 的优化：Hadoop 每次 MapReduce 操作，启动一个 Task 便会启动一次 JVM，基于进程的操作。而 Spark 每次 MapReduce 操作是基于线程的，只在启动 Executor 是启动一次 JVM，内存的 Task 操作是在线程复用的。每次启动 JVM 的时间可能就需要几秒甚至十几秒，那么当 Task 多了，这个时间 Hadoop 不知道比 Spark 慢了多少

Spark 的依赖容错机制

Spark 的依赖分为窄依赖和宽依赖，**窄依赖**是父 rdd 的每个分区最多被一个子 rdd 的分区引用，表现为一个父 rdd 的分区对应一个子 rdd 的分区或者多个父 rdd 的分区对应于一个子 rdd 的分区。**宽依赖**是子 rdd 的分区依赖于父 rdd 的多个分区或者全部分区，即存在一个父 rdd 的一个分区对应一个子 rdd 的多个分区。

在容错机制中，如果一个节点死机了，而且运算窄依赖，则只要把丢失的父 RDD 分区重算即可，不依赖于其他节点。而宽依赖需要父 RDD 的所有分区都存在，重算就很昂贵了。可以这样理解开销的经济与否：在窄依赖中，在子 RDD 的分区丢失、重算父 RDD 分区时，父 RDD 相应分区的所有数据都是子 RDD 分区的数据，并不存在冗余计算。在宽依赖情况下，丢失一个子 RDD 分区重算的每个父 RDD 的每个分区的所有数据并不是都给丢失的子 RDD 分区用的，会有一部分数据相当于对应的是未丢失的子 RDD 分区中需要的数据，这样就会产生冗余计算开销，这也是宽依赖开销更大的原因。因此如果使用 Checkpoint 算子来做检查点，不仅要考虑 Lineage 是否足够长，也要考虑是否有宽依赖，对宽依赖加 Checkpoint 是最物有所

值的。

Checkpoint 机制与 cache

当 spark 应用程序特别复杂，从初始的 RDD 开始到最后整个应用程序完成有很多的步骤，而且整个应用运行时间特别长，这种情况下就比较适合使用 checkpoint 功能。
最主要的区别在于持久化只是将数据保存在 BlockManager 中，但是 RDD 的 lineage(血缘关系，依赖关系)是不变的。但是 checkpoint 执行完之后，rdd 已经没有之前所谓的依赖 rdd 了，而只有一个强行为其设置的 checkpointRDD，checkpoint 之后 rdd 的 lineage 就改变了。持久化的数据丢失的可能性更大，因为节点的故障会导致磁盘、内存的数据丢失。但是 checkpoint 的数据通常是保存在高可用的文件系统中，比如 HDFS 中，所以数据丢失可能性比较低。

Spark 宕机的几种情况和解决办法

Driver 进程宕机：1）如果是机器宕机，则重启机器及 spark 程序。2）如果是应用程序执行失败，则重启程序即可。在 sparkStreaming 中，重启程序可以通过 checkpoint 进行 job 数据恢复
Executor 进程宕机：选择一个 worker 节点重新启动 Executor 进程，Driver 重新分配任务
Task 执行失败：1）spark 程序会进行任务重试，如果某个 task 失败重试超过 3 次后，当前 job 失败。2）task 数据恢复/重新运行的机制实际上是 RDD 的容错机制。3）如果血缘过长，可以通过设置检查点或缓存，将数据冗余的保存下来，当 task 出现异常时，可以在检查点处构建血缘关系，进行错误恢复，减少执行开销

Yarn clent 与 yarn cluster 的区别

从广义上讲，yarn cluster 模式适合生产环境，而 yarn clent 模式适合于交互和调试，可以快速看到 application 的输出。从深层含义来讲，二者的主要区别是 application master 进程的区别。Yarn cluster 模式下，driver 运行在 application master 中，负责向 yarn 申请资源，监督作业的运行情况。当用户提交作业后，client 就可以关闭了，作业会继续在 yarn 上运行。然而 cluster 模式不适合运行交互类型的作业。而在 clent 模式下，application master 仅仅向 yarn 申请 container，client 跟 container 通信来调度他们的工作，也就是说 client 不能离开

减少内存的使用方式

1. 数据结构优先使用基本类型和对象数组，而不是标准的 java 或 scala 集合类（例如 hashmap）
2. 尽量避免使用包含大量小对象和指针的嵌套结构
3. 序列化 rdd 存储，使用 kryo 方式，存储格式选用 MEMORY_ONLY_SER

Spark 的序列化方式

以序列化形式存储 RDD，以减少内存使用以及 gc 的开销
在 spark 中具有两种序列化方式，分别是 java 序列化，通过继承 Serializable 实现，另一种是 kryo 序列化。
Java 序列化方式使用灵活，但是速度慢。在某些情况下序列化的结果也比较大
Kryo 比 Java 序列化（通常高达 10 倍）明显更快，更紧凑，但不支持所有 Serializable 类型，并且要求提前注册您将在程序中使用的类，以获得最佳性能。
conf.set("spark.serializer", "org.apache.spark.serializer.KryoSerializer"
val conf = new SparkConf().setMaster(...).setAppName(...)
要使用 Kryo 注册自己的自定义类，使用 registerKryoClasses 方法。
conf.registerKryoClasses(Array(classOf[MyClass1], classOf[MyClass2]))
val sc = new SparkContext(conf)
如果没有注册自定义类，Kryo 仍然会工作，但它必须存储每个对象的完整类名，这是浪费的。

防止 OOM 可能的方法

1. 如果 Minor GC 过多，说明 Eden 的内存过少，可以添加 Eden 的内存
2. 添加并行度，减少每个 task 的数据量
3. 广播大变量

sparkStreaming 调优

序列化，广播大变量，设置合理的批处理间隔，缓存反复使用的 Dstream（RDD）
合理的 Kafka 拉取量（maxRatePerPartition 参数设置）：对于数据源是 Kafka 的 Spark Streaming 应用，在 Kafka 数据频率过高的情况下，调整这个参数是非常必要的。我们可以改变 spark.streaming.kafka.maxRatePerPartition 参数的值来进行上限调整，默认是无上限的，即 Kafka 有多少数据，Spark Streaming 就会一次性全拉出，但是上节提到的批处理时间是一定的，不可能动态变化，如果持续数据频率过高，同样会造成数据堆积、阻塞的现象

groupbykey 与 reducebykey 的区别

reduceByKey 用于对每个 key 对应的多个 value 进行 merge 操作，最重要的是它能够在本地先进行 merge 操作，并且 merge 操作可以通过函数自定义。当采用 reduceByKey 时，Spark 可以在每个分区移动数据之前将待输出数据与一个共用的 key 结合。当采用 groupByKey 时，由于它不接收函数，spark 只能先将所有的键值对(key-value pair)都移动，这样的后果是集群节点之间的开销很大，导致传输延时

执行一个 sparkStreaming 程序需要注意的事项

1. 将程序打包成一个 jar 包,通过 spark-submit 提交,对于一些额外的依赖包,比如 kafka 的，可以在提交时指定，通过—package
2. 为每个 executor 配置足够的内存，因为接收到的流数据存放在内存中，比如十分钟一个批次，则需要能够存放十分钟数据的内存
3. 配置检查点，用于故障恢复
4. 配置应用程序的驱动程序的自动重新启动，要自动从驱动程序故障中恢复，用于运行流应用程序的部署基础结构必须监视驱动程序进程并在驱动程序失败时重新启动驱动程序。 不同的集群管理器有不同的工具来实现这一点
5. 配置预写日志，自 Spark 1.2 起，我们引入了预写日志以实现强大的容错保证。如果启用，则从接收器接收的所有数据都将写入配置检查点目录中的预写日志。这可以防止驱动程序恢复时的数据丢失，从而确保零数据丢失。将 spark.streaming.receiver.writeAheadLog.enable 设置为 true 来启用此功能。然而，这些更强的语义可能以单个接收器的接收吞吐量为代价。这可以通过并行运行更多接收器来更正聚合吞吐量来纠正。此外，建议在启用预写日志时禁用 Spark 中接收数据的复制，因为日志已存储在复制存储系统中。
6. 设置最大接收速率，如果群集资源不足以使流应用程序以接收数据的速度处理数据，则可以通过设置记录/秒的最大速率限制来限制接收器。 spark.streaming.receiver.maxRate 和 Direct Kafka 方法的 spark.streaming.kafka.maxRatePerPartition。 在 Spark 1.5 中，我们引入了一项称为背压的功能，无需设置此速率限制，因为 Spark Streaming 会自动计算出速率限制，并在处理条件发生变化时动态调整它们。 可以通过将配置参数 spark.streaming.backpressure.enabled 设置为 true 来启用此背压。

SparkStreaming 程序更新需要注意的事项

1. 新旧程序同时运行，消费同一份数据。当新的程序消费到与旧程序数据一致时，旧的就可以停掉

SparkStreaming 与 kafka 两种集成方式与优缺点

sparkStreaming 与 kafka 有两种集成方式，分别为 **receiver** 与 **direct** 模式。

receiver 模式：采用 push 的方式，调用高层次的 API，在实际的生产环境中，该方式使用的不多。主要是因为该方式将接收到的数据存放在 executor 中，然后由 sparkStreaming 启动的作业处理数据。但是，在默认配置下，这种方法可能会在失败时丢失数据。为了确保零数据丢失，必须在 Spark Streaming 中额外启用写入日志，同时保存所有接收到的 Kafka 数据写入分布式文件系统（例如 HDFS）的预先写入日志，以便所有数据都可以在失败时恢复。

缺点：

1. kafka 中的主题分区与 sparkStreaming 中生成的 RDD 的分区不相关
2. 为防止数据丢失,需要开启 wal 机制,降低了数据的处理效率,另外由于数据备份机制,负载一高就会出现延迟的风险，导致应用崩溃
3. 单 receiver 内存，由于 receiver 也属于 executor 的一部分，那么为了提高吞吐量，需要提高 receiver 的内存。但是在每次的 batch 的计算中参与计算的 batch 并不需要那么的内存，导致资源的浪费

4. Receiver 和计算的 executor 是异步的，那么遇到网络等的因素，导致计算出现延迟，计算队列一直在增加而 receiver 一直在接收数据，这非常容易导致程序崩溃
5.

优点：

1. Kafka 的 high-level 数据读取方式让用户可以专注于所读数据，而不用关注或维护 consumer 的 offsets，这减少用户的工作量以及代码量而且相对比较简单。
2.

Direct 模式：采用 pull 方式，从 kafka 中拉取数据，使用 kafka 的低级 API。此法提供了更强大的端到端保证。它定期查询 Kafka 在每个 topic+分区(partition)中的最新偏移量，而不再使用接收器去接收数据。同时，它也定义了要在每个批次中处理的不同偏移范围。特别是在那些处理数据的作业被启动时，其简单消费者(consumer)API 就会被用于读取 Kafka 中预定义的偏移范围。可见，此过程类似于从某个文件系统中读取各种文件

优点：

1. 简化并行，不需要创建以及 union 多输入源，kafka 的 topic 分区数与 RDD 的 partition 数一一对应
2. 降低资源，direct 不需要 receiver，其申请的 executors 全部用于计算。而 receiver 需要专门的 receivers 来读取数据且不参与计算。因此相同的资源申请，direct 能够支持更大的业务
3. 鲁棒性更好，Receiver-based 方法需要 Receivers 来异步持续不断的读取数据，因此遇到网络、存储负载等因素，导致实时任务出现堆积，但 Receivers 却还在持续读取数据，此种情况很容易导致计算崩溃。Direct 则没有这种顾虑，其 Driver 在触发 batch 计算任务时，才会读取数据并计算。队列出现堆积并不会引起程序的失败。

缺点：

1. 提高成本，Direct 需要用户采用 checkpoint 或者第三方存储来维护 offsets，而不像 receiver 那样通过 zookeeper 维护 offsets，提高了开发成本
2. 监控可视化，receiver 的消费情况可以通过 zookeeper 来监控，而 direct 模式则不可以

Hive 篇

数据倾斜问题

解决办法：

1. 参数调优：set hive.map.aggr=true 在 map 端做部分聚合操作，效率更高，但需要更多的内存；set hive.groupby.skewindata=true;数据倾斜时负责负载均衡，设为 true 时会生成两个 MRJob，它使计算变成了两个 mapreduce，第一个在 shuffle 时随机给 key 打标记，使每个 key 随机均匀分布到各个 reduce 上计算，但是这样只能完成部分计算，因为相同 key 没有分配到相同 reduce 上，所以需要第二次的 mapreduce,这次就回归正常 shuffle,但是数据分布不均匀的问题在第一次 mapreduce 已经有了很大的改善，因此基本解决数据倾斜。

2. 调节 key:在 map 阶段将造成数据倾斜的 key 先分成多组，例如 aaa 这个 key，在 map 时随机在后面添加 1，2，3，4 这四个数字，分成四组，先进行一次计算，之后恢复 key 正常运算
3. 能先进行 group 操作的时候进行 group 操作，把 key 先进行一次 reduce 操作，之后再进行 count
4. Join 操作中，对于小表与大表 join，使用 map join，免得 reduce 时卡住。
5. 当对三个或者更多个表进行 join 连接时，如果每个 on 子句都使用相同的连接键的话，那么只会产生一个 mr job

Hive 优化

1. **数据存储与压缩**。针对 hive 中表的存储格式通常有 orc 和 parquet，压缩格式一般使用 snappy。相比与 textfile 格式表，orc 占有更少的存储。因为 hive 底层使用 MR 计算架构，数据流是 hdfs 到磁盘再到 hdfs，而且会有很多次，所以使用 orc 数据格式和 snappy 压缩策略可以降低 IO 读写，还能降低网络传输量，这样在一定程度上可以节省存储，还能提升 hql 任务执行效率
2. **Sql 优化**。大表对大表：尽量减少数据集，可以通过分区表，避免扫描全表或者全字段
   大表对小表：设置自动识别小表，将小表放入内存中去执行
3. **通过参数调优**。并行执行，调节 parallel 参数；调节 jvm 参数，重用 jvm；设置 map、reduce 的参数；开启 strict mode 模式；关闭推测执行设置。

仓库规范

分层：
1. 把复杂问题简单化，把一个复杂问题分成多个步骤完成，每一层只完成单一步骤，比较简单。而且方便定位问题
2. 减少重复开发，规范数据分层。通过中间层，能够减少较大的重复计算，增加一次结果的复用性
3. 隔离原始数据

仓库通常分为四层
1. ods 层：原始数据层，保存原始数据，不做处理
2. dwd 层：结构和粒度与原始层保持一致，对 ods 层数据进行清洗（去除空值，脏数据，超过极限范围的数据）
3. dws 层：以 dwd 为基础，进行轻度汇总
4. ads 层：为各种统计报表提供数据

关于不等值连接问题

在 hive 中是不支持不等连接的，比如 select u1.*,u2.* from user_info u1 join user_info u2 on u1.age>u2.age;是会报错，提示不支持该操作，在 mysql 中，上述操作是可以支持的。

Hive 与 hbase 的联系

共同点：

1. hive 和 hbase 都是架构在 hadoop 之上的，都是使用 hdfs 作为底层存储

不同点：

1. hive 中的表是逻辑表，仅仅对表的元数据进行定义，没有物理存储的功能。完全依赖于 hdfs 与 mapreduce。将结构化的文件映射成一张数据库表，并提供完整的 sql 查询，并将 sql 语句最终转换为 mr 任务进行运行。Hbase 表则是物理表，适合存放非结构化的数据。
2. hive 是在 mapreduce 基础之上对数据进行处理，而 mapreduce 的数据处理按照行模式。Hbase 为列模式，使得对海量数据的随机查询变得可能
3. hive 全面支持 sql，一般用来进行基于历史数据的挖掘，分析。Hbase 不适用于有 join，多极索引，表关系复杂的应用场景。
4. hbase 是物理表，不是逻辑表，提供一个超大的内存 hash 表，搜索引擎通过它来存储索引，方便查询操作

hive 中存放的是什么

hive 中存放的是和 hdfs 的映射关系，hive 是逻辑上的数据仓库，实际上操作的都是 hdfs 文件。HQL 就是用 sql 语法来写的 mr 程序

UDAF 与 UDTF

UDAF：用户自定义聚合函数，用于输入多行，输出一行，比如 sun（），avg()等。
UDTF：用户自定义表生成函数，用于输入一行，输出多行，比如 explode（）

Hbase 篇

Rowkey 设计规范

Hbase 表的数据是按照 rowkey 来分散到不同的 region，不合理的 rowkey 设计会导致热点问题。热点问题指的是直接访问集群一个或极少数节点，而集群中其他节点处于空闲状态。
rowkey 设计加盐：在 rowkey 头部随机添加一个字符，将数据分散到不同的 region 上，有利于写操作，但增加读开销。可以很好的支持去全表扫描
hashing 方式：计算 rowkey 的 hash 值，然后取部分 hash 值与进行拼接原 rowkey。可以一定程度打散整个数据集，但是不利于 scan 操作。对 hash 操作可以采用 md5 算法。
rowkey 反转：如果先导字体本身会带来热点问题，但该字段尾部信息却具有良好的随机性，此时可以考虑将先导字体做反转处理，将尾部几位直接提到前面，或直接将整个字段反转

hbase 的应用场景

对象存储：我们知道不少的头条类、新闻类的的新闻、网页、图片存储在 HBase 之中，一些病毒公司的病毒库也是存储在 HBase 之中
时序数据：HBase 之上有 OpenTSDB 模块，可以满足时序类场景的需求
推荐画像：特别是用户的画像，是一个比较大的稀疏矩阵，蚂蚁的风控就是构建在 HBase 之上
时空数据：主要是轨迹、气象网格之类，滴滴打车的轨迹数据主要存在 HBase 之中，另外在技术所有大一点的数据量的车联网企业，数据都是存在 HBase 之中
CubeDB OLAP：Kylin 一个 cube 分析工具，底层的数据就是存储在 HBase 之中，不少客户自己基于离线计算构建 cube 存储在 hbase 之中，满足在线报表查询的需求
消息/订单：在电信领域、银行领域，不少的订单查询底层的存储，另外不少通信、消息同步的应用构建在 HBase 之上
Feeds 流：典型的应用就是 xx 朋友圈类似的应用
NewSQL：之上有 Phoenix 的插件，可以满足二级索引、SQL 的需求，对接传统数据需要 SQL 非事务的需求

Hmaster 的作用

1. 为 regionServer 分配 region
2. 负责 regionserver 的负载均衡
3. Regionserver 失效时，重新分配其上的 region
4. Gfs 文件上的垃圾文件回收
5. 处理 schema 更新请求

Kafka 篇

常见参数配置

auto.create.topics.enable：是否允许自动创建 topic
unclean.leader.election.enable：是否允许 Unclean Leader 选举
auto.leader.rebalance.enable：是否允许定期进行 Leader 选举
log.retention.{hour|minutes|ms}：控制一条消息被保留的时间

分区的作用

分区的作用就是提供负载均衡的能力，或者说对数据分区就是实现系统的高伸缩性。不同的分区被放置到不同的机器节点上，这样每个机器可以执行各自分区的读写请求，还可以通过增加机器数来提升系统整体的吞吐性。

Kafka 高吞吐量的原因

1. 顺序写入
2. 零拷贝：就是跳过“用户缓冲区”的拷贝，建立一个磁盘空间和内存的直接映射，数据不再复制到“用户态缓冲区”
3. 分区：kafka 中的 topic 中的内容可以被分为多分 partition 存在,每个 partition 又分为多个段 segment,所以每次操作都是针对一小部分做操作，很轻便，并且增加并行操作的能力

什么是零拷贝

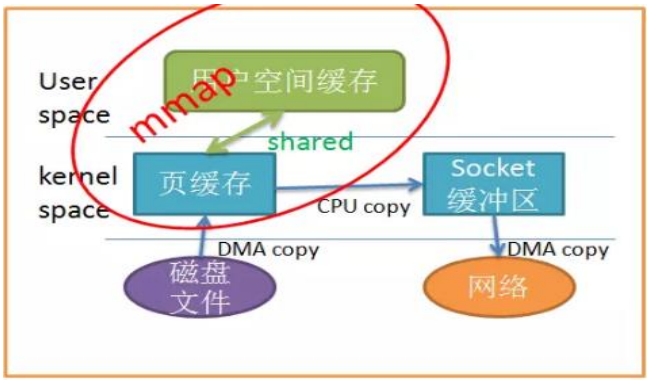

从上图中可以看出，共产生了四次数据拷贝，即使使用了 DMA 来处理了与硬件的通讯，CPU 仍然需要处理两次数据拷贝，与此同时，在用户态与内核态也发生了多次上下文切换，无疑也加重了 CPU 负担。在此过程中，我们没有对文件内容做任何修改，那么在内核空间和用户空间来回拷贝数据无疑就是一种浪费，而零拷贝主要就是为了解决这种低效性。

消费者组

消费者组是 kafka 提供的可扩展，且具有容错性的消费者机制。组下具有多个消费者实例，组内的所有消费者协调在一起共同消费订阅主题的所有分区,每个分区只能由同一个消费者组的一个实例消费。**理想情况下，消费者实例的个数应当等于组内所有主题的分区数之和，过大则会浪费资源，过小则会导致每个实例多个分区，消费速度缓慢**。在 sparkstreamign 消费 kafka 时，direct 方式的消费实例数就等于所有 topic 的分区总数

谈谈 kafka 的重平衡问题

Rebalance 本质上一种协议，规定了一个 group 下的所有 consumer 如何达成一致，来分配订阅 topic 的每个分区。比如某个 group 下有二十个消费者，订阅了一个具有 100 个分区的主题。正常情况下，kafka 为每个消费者分配五个分区，这个过程就叫做重平衡。**当消费者个数变化，主题个数变化，主题的分区数目变化时，就会导致 Rebalance 触发。重新分配分**

区给消费者，期间所有消费者停止消费，等待 Rebalance 完成，代价非常高
解决不必要的重平衡方法（由 consumer 引起的）：

1， consumer 未能及时发送心跳到 Coordinator，导致 consumer 被剔除 group，可以通过调节 session.timeout.ms(超过这个时间没有收到消息则认为 consumer 死亡，从而将 consumer 剔除，启动 rebalance)和 heartbeat.interval.ms(consumer 每隔多长时间发送心跳)
2， 由于 consumer 消费时间过长导致 rebalance，可通过调大 max.poll.internal.ms(如果 consumer 在规定时间内没有将一次 poll 到的数据消费完，则将该 consumer 剔除)可以适当的调大

Kafka 的位移管理

在老版本的 kafka 中，将位移信息存放在 zookeeper 中，每次启动 consumer 时，自动从 zookeeper 中读取位移信息，从而在上次截止的地方继续消费。由于 zookeeper 更新不及时问题会导致重复消费，同时 zookeeper 也不适合这种高频的写操作。因此在新版本中将位移信息提交到作为一条条 kafka 消息__consumer_offsets（位移主题）中。消息格式为 kv 对，key 为<groupID->主题名->分区号>，value 为位移等相关信息。

Kafka 的 CommitFailedExecption 原因及处理方案

该异常的发生原因是在两次调用 poll 方法的时间间隔到之后数据还没有处理完。在该情况下提交位移时就会抛出该异常

```
Properties props = new Properties();
props.put("max.poll.interval.ms", 5000);
consumer.subscribe(Arrays.asList("test-topic"));
while (true) {
    ConsumerRecords<String, String> records =
        consumer.poll(Duration.ofSeconds(1));
    // 使用 Thread.sleep 模拟真实的消息处理逻辑
    Thread.sleep(6000L);
    consumer.commitSync();
}
```

解决方法：

1. 增加期望的时间间隔，max.poll.interval.ms 参数值
2. 减少 poll 方法一次性返回的消息数量，即减少，max.poll.records 参数值
3. 缩短单条消息的处理时长

Kafka 的副本机制了解下

副本机制就是备份机制，在多台网络互联的机器上保存相同的数据拷贝。通常来说，副本机制拥有以下好处。

1. **提供数据冗余：**即使系统部分组件失效，系统依然可以继续运转

2. **提供高伸缩性：**支持横向扩展，通过增加机器的数目来提升读性能
3. **改善数据局部性：**允许将数据放入与用户地理位置相近的地方，从而降低数据延时

对于 kafka 来说，只能享有分区的第一个特性（副本机制）。只有领导者副本提供服务，从副本定期从主副本拉取数据进行数据同步。该设计的目的有以下两点：

1. **方便实现 Read-your-writes：**往 kafka 写入一条消息后，马上就能通过消费者 API 读取到数据。如果允许允许追谁者副本对外提供服务，由于 kafka 采用异步同步数据，有可能追随者副本还没有拉取到最新消息，从而在客户端看不到最新写入的消息。
2. **方便实现单调读：**对于一个消费者而言，在多次消费消息时，他不会看到某条消息一会存在一会不存在。如果允许允许追谁者副本对外提供服务，比如两个副本 F1，F2，先读取 F1 时看到最新的消息，在读取 F2 时，由于更新不及时，看到的数据不全，导致两次读取到的数据不一致问题

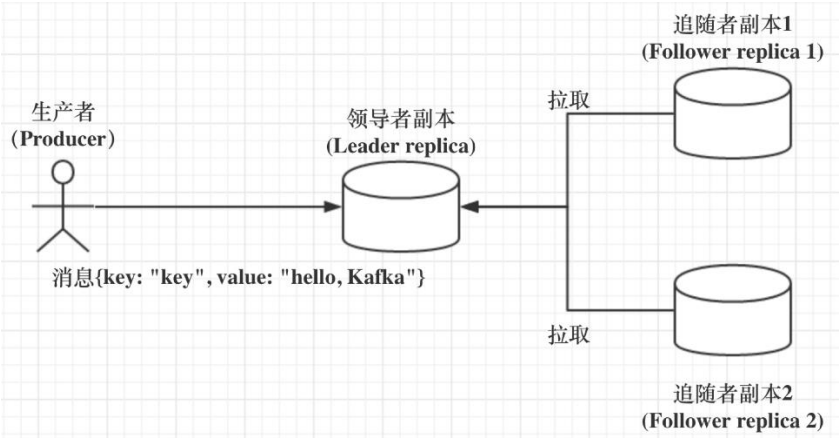

ISR 副本集合

ISR 中的副本都是与 leader 副本同步的副本，leader 副本天然在 ISR 副本中。

Broker 端的参数 replica.lag.time.max.ms 控制着其它副本是否与 leader 副本是同步副本，若从副本落后的时间超过前面参数规定的最大时间，则表明不是同步副本，从 ISR 中剔除，否则就是同步副本。如果被踢除的副本后面又追上了 leader 的进度，那么它是能够被重新加回 ISR 的。当 leader 挂掉后，从 ISR 集合中选举一个副本作为 leader 继续对外提供服务。如果 ISR 集合为空，如果将 ISR 外的副本作为 leader 就是 unclean 选举，此时由于该副本落后 leader 太多，会导致数据丢失，一般不建议采用，通过参数 **unclean.leader.election.enable** 控制，建议设为 false